Introducción a Pandas

¿Qué es Pandas?

- Pandas es una biblioteca de Python especializada en la manipulación y análisis de datos. Ofrece estructuras de datos eficientes para manejar grandes volúmenes de información y herramientas para limpieza, transformación y visualización de datos.
- Pandas nos permite analizar big data y scar conclusiones basadas en teorías estadísticas.
- Pandas puede limpiar conjuntos de datos desordenados y hacerlos legibles y relevantes.

Ventajas de Pandas.

- Permite trabajar con datos tabulares (similares a Excel o SQL)
- Facilita la manipulación y limpieza de datos.
- Compatible con otras Bibliotecas como NumPy y Matplotlib.
- Soporta multiples formatos de datos (CSV, Excel, SQL, JSON)

Instalción y uso de Pandas

- Para instalar Pandas podemos usar el siguiente comando desde la terminal o desde una celda de Jupyer.

In [4]:
```
# Directo de la celda
%pip install pandas
#pip install pandas desde la termimal
```

```
Requirement already satisfied: pandas in c:\python\python311\lib\site-packages (2.
2.1)Note: you may need to restart the kernel to use updated packages.
[notice] A new release of pip is available: 24.0 -> 25.0.1
[notice] To update, run: python.exe -m pip install --upgrade pip
Requirement already satisfied: numpy<2,>=1.23.2 in c:\python\python311\lib\site-pa
ckages (from pandas) (1.26.3)
Requirement already satisfied: python-dateutil>=2.8.2 in c:\users\lalo\appdata\roa
ming\python\python311\site-packages (from pandas) (2.8.2)
Requirement already satisfied: pytz>=2020.1 in c:\python\python311\lib\site-packag
es (from pandas) (2024.1)
Requirement already satisfied: tzdata>=2022.7 in c:\python\python311\lib\site-pack
ages (from pandas) (2024.1)
Requirement already satisfied: six>=1.5 in c:\users\lalo\appdata\roaming\python\py
thon311\site-packages (from python-dateutil>=2.8.2->pandas) (1.16.0)
```

Podemos instalar mas de una Liberia juntas. Desde la consola pip install pandas numpy matplotlib seaborn

Vamos a verificar la instalación.

In [6]:
```
import pandas as pd
print(pd.__version__)
pd.show_versions()
```

```
2.2.1
```

```
c:\Python\Python311\Lib\site-packages\_distutils_hack\__init__.py:33: UserWarning:
Setuptools is replacing distutils.
  warnings.warn("Setuptools is replacing distutils.")
```

```
INSTALLED VERSIONS
------------------
commit                : bdc79c146c2e32f2cab629be240f01658cfb6cc2
python                : 3.11.0.final.0
python-bits           : 64
OS                    : Windows
OS-release            : 10
Version               : 10.0.19045
machine               : AMD64
processor             : Intel64 Family 6 Model 78 Stepping 3, GenuineIntel
byteorder             : little
LC_ALL                : None
LANG                  : None
LOCALE                : Spanish_Mexico.1252

pandas                : 2.2.1
numpy                 : 1.26.3
pytz                  : 2024.1
dateutil              : 2.8.2
setuptools            : 65.5.0
pip                   : 24.0
Cython                : None
pytest                : None
hypothesis            : None
sphinx                : None
blosc                 : None
feather               : None
xlsxwriter            : None
lxml.etree            : 5.3.0
html5lib              : None
pymysql               : None
psycopg2              : None
jinja2                : 3.1.2
IPython               : 8.6.0
pandas_datareader     : None
adbc-driver-postgresql: None
adbc-driver-sqlite    : None
bs4                   : 4.12.2
bottleneck            : None
dataframe-api-compat  : None
fastparquet           : None
fsspec                : 2023.12.2
gcsfs                 : None
matplotlib            : 3.6.3
numba                 : None
numexpr               : None
odfpy                 : None
openpyxl              : None
pandas_gbq            : None
pyarrow               : None
pyreadstat            : None
python-calamine       : None
pyxlsb                : None
s3fs                  : None
scipy                 : 1.15.1
sqlalchemy            : None
tables                : None
tabulate              : None
xarray                : None
xlrd                  : None
zstandard             : None
tzdata                : 2024.1
qtpy                  : 2.3.1
pyqt5                 : None
```

Estructuras de datos con Pandas.

- Pandas trabaja principalmente con Series y DataFrames.

Series.

- Una serie es una estructura de datos similar a una lista, pero con etiquetas de índice.

In [7]:
```
import pandas as pd

# Crear una Series con una lista
datos = [10, 20, 30, 40]
serie = pd.Series(datos)

print(serie)
```

```
0    10
1    20
2    30
3    40
dtype: int64
```

In [8]:
```
serie = pd.Series([10, 20, 30, 40], index=["a", "b", "c", "d"])
print(serie)
```

```
a    10
b    20
c    30
d    40
dtype: int64
```

DataFrame (Tablas bidimensionales)

- Un DataFrame es una estructura tabular similar a una hoja de cálculo de Excel o una tabla de SQL.

In [9]:
```
# Crear un DataFrame a partir de un diccionario
datos = {
    "Nombre": ["Ana", "Luis", "Carlos"],
    "Edad": [25, 30, 35],
    "Ciudad": ["Madrid", "Barcelona", "Valencia"]
}

df = pd.DataFrame(datos)
print(df)
```

```
   Nombre  Edad     Ciudad
0     Ana    25     Madrid
1    Luis    30  Barcelona
2  Carlos    35   Valencia
```

In [11]:
```
print("\nAccedemos a una columna")
print(df['Nombre'])

print("\nAccedemos a una fila por indice")
print(df.loc[1])
```

```
Accedemos a una columna
0       Ana
1      Luis
2    Carlos
Name: Nombre, dtype: object

Accedemos a una fila por indice
Nombre         Luis
Edad             30
Ciudad    Barcelona
Name: 1, dtype: object
```

Operaciones Básicas en Pandas.

Creación de DataFrames y Series.

- Ya vimos cómo crear Series y DataFrames, pero ahora exploraremos más formas de hacerlo.
- Una Serie de Pandas es como una columna en una tabla.
- Es una matriz unidimensional que contiene datos de cualquier tipo.
- Si no se especifica nada más, los valores se etiquetan con su número de índice. El primer valor tiene índice 0, el segundo tiene índice 1.

Crear un DataFrame desde una lista de listas

In [13]:
```python
import pandas as pd

datos = [
    ["Ana", 25, "Mexico"],
    ["Luis", 30, "Canada"],
    ["Carlos", 35, "Cuba"]
]

df = pd.DataFrame(datos, columns=["Nombre", "Edad", "Ciudad"])
print(df)
```

```
   Nombre  Edad  Ciudad
0     Ana    25  Mexico
1    Luis    30  Canada
2  Carlos    35    Cuba
```

Indexación y Selección de Datos.

- Pandas ofrece múltiples fomras de acceder a los datos dentro de un DataFrame o Serie.

In [14]:
```python
print("\nAcceder a una columna")
print(df["Nombre"])

print("\nAcceder a una fila por indice")
print(df.loc[1])

print("\nAcceder a una celda especifica")
print(df.at[1, "Edad"])
```

```
Acceder a una columna
0       Ana
1      Luis
2    Carlos
Name: Nombre, dtype: object

Acceder a una fila por indice
Nombre      Luis
Edad          30
Ciudad    Canada
Name: 1, dtype: object

Acceder a una celda especifica
30
```

Filtrado de datos.

In [19]:
```
print("\nFiltrar filas según la condición")
df_filtrado = df[df["Edad"] > 28]
print(df_filtrado)

print("\nFiltrar filas con múltiples condiciones")
df_filtrado = df[(df["Edad"] > 25) & (df["Ciudad"] == "Canada")]
print(df_filtrado)
```

```
Filtrar filas según la condición
   Nombre  Edad  Ciudad
1    Luis    31  Canada
2  Carlos    36    Cuba

Filtrar filas con múltiples condiciones
  Nombre  Edad  Ciudad
1   Luis    31  Canada
```

Modificación de datos.

In [20]:
```
print("\nModificar valores de una columna.")
df["Edad"] = df["Edad"] + 1
print(df)

print("\nModificar un valor especifico.")
df.at[0, "Ciudad"] = "Paris"
print(df)
```

```
Modificar valores de una columna.
   Nombre  Edad  Ciudad
0     Ana    27   Paris
1    Luis    32  Canada
2  Carlos    37    Cuba

Modificar un valor especifico.
   Nombre  Edad  Ciudad
0     Ana    27   Paris
1    Luis    32  Canada
2  Carlos    37    Cuba
```

Manipulación y limpieza de Datos con Pandas

- En este apartado aprenderemos a manejar valores nulos, eliminar duplicado, transformar datos y aplicar funciones para limpiar y preparar los datos antes del análisis.

Manejo de valores nulos.

- En Pandas, los valores nulos se representan con NaN (Not a Number). Podemos encontrarlos y tratarlos de varias formas.

In [21]:
```
import pandas as pd
import numpy as np

print("\nIDENTIFICANDO VALORES NULOS")

datos = {
    "Nombre": ["Ana", "Luis", "Carlos", np.nan],
    "Edad": [25, np.nan, 35, 40],
    "Ciudad": ["Madrid", "Barcelona", np.nan, "Sevilla"]
}

df = pd.DataFrame(datos)
print(df)
print("\nValores nulos por columna:\n", df.isnull().sum())
```

```
IDENTIFICANDO VALORES NULOS
   Nombre  Edad     Ciudad
0     Ana  25.0     Madrid
1    Luis   NaN  Barcelona
2  Carlos  35.0        NaN
3     NaN  40.0    Sevilla

Valores nulos por columna:
 Nombre    1
Edad      1
Ciudad    1
dtype: int64
```

In [22]:
```
print("\nEliminar valores nulos")
df_sin_nulos = df.dropna()  # Elimina las filas que contienen NaN
print(df_sin_nulos)


print("\nRellenar valores nulos")
df_relleno = df.fillna({"Nombre": "Desconocido", "Edad": df["Edad"].mean(), "Ciudad
print(df_relleno)
```

```
Eliminar valores nulos
  Nombre  Edad  Ciudad
0    Ana  25.0  Madrid

Rellenar valores nulos
        Nombre       Edad           Ciudad
0          Ana  25.000000           Madrid
1         Luis  33.333333        Barcelona
2       Carlos  35.000000  No especificado
3  Desconocido  40.000000          Sevilla
```

Eliminación de duplicados.

- Podemos detectar y eliminar datos duplicados con estas funciones.

In [25]:
```
print("\nEncontrando duplicados.")

df = pd.DataFrame({
    "Nombre": ["Ana","Pao","Lalo","Ana"],
    "Edad": [25,30,35,25]
})
print(df.duplicated())
```

```
print("\nEliminando duplicados.")
df_sin_dup = df.drop_duplicates()
print(df_sin_dup)
```

```
Encontrando duplicados.
0    False
1    False
2    False
3     True
dtype: bool

Eliminando duplicados.
  Nombre  Edad
0    Ana    25
1    Pao    30
2   Lalo    35
```

Eliminar filas con muchos valores nulos.

- Si una fila tiene demasiados valores NaN, puede ser mejor eliminarla.

Eliminar filas con más del 50% de valores nulos.

In [26]:
```
df = pd.DataFrame({
    "Nombre": ["Ana", "Luis", np.nan, "María", "Sofía"],
    "Edad": [25, np.nan, np.nan, 22, 22],
    "Salario": [5000, np.nan, np.nan, 4800, 5100]
})

df_limpio = df.dropna(thresh=2)  # Al menos 2 valores no nulos
print(df_limpio)
```

```
  Nombre  Edad  Salario
0    Ana  25.0   5000.0
3  María  22.0   4800.0
4  Sofía  22.0   5100.0
```

Rellenar valores nulos de una columna basado en otra.

- Podemos asignar valores faltantes basándonos en otra columna.

Asignar la media de Salario según la Edad

In [27]:
```
df["Salario"] = df.groupby("Edad")["Salario"].transform(lambda x: x.fillna(x.mean()
print(df)
```

```
  Nombre  Edad  Salario
0    Ana  25.0   5000.0
1   Luis   NaN      NaN
2    NaN   NaN      NaN
3  María  22.0   4800.0
4  Sofía  22.0   5100.0
```

Reemplazar valores nulos con datos externos.

- Podemos usar un diccionario de valores predefinidos.

Rellenar con valores específicos según la columna.

In [28]:
```
df.fillna({"Edad": 30, "Salario": 4000}, inplace=True)
print(df)
```

```
  Nombre  Edad  Salario
0    Ana  25.0   5000.0
1   Luis  30.0   4000.0
2    NaN  30.0   4000.0
3  María  22.0   4800.0
4  Sofía  22.0   5100.0
```

Transformaciones y Operaciones Matemáticas

- Pandas permite aplicar operaciones aritméticas y funciones sobre los datos de una DataFrame

In [26]:
```
print("\nAplicando operaciones matemáticas a una columna.")
df["Edad"] = df["Edad"] + 1
print(df)

print("\nAplicar una función a una columna.")
df["Categoria_Edad"] = df["Edad"].apply(lambda x: "Joven" if x < 30 else "Adulto")
print(df)
```

```
Aplicando operaciones matemáticas a una columna.
  Nombre  Edad
0    Ana    26
1    Pao    31
2   Lalo    36
3    Ana    26

Aplicar una función a una columna.
  Nombre  Edad Categoria_Edad
0    Ana    26          Joven
1    Pao    31         Adulto
2   Lalo    36         Adulto
3    Ana    26          Joven
```

Aplicación de funciones personalizadas.

- Podemos definir nuestras propias funciones y aplicarlas a un DataFrame.

In [27]:
```
print("\nConvertir nombres a mayusculas.")
print("-------------------------------")
df["Nombre"] = df["Nombre"].apply(lambda x: x.upper())
print(df)
```

```
Convertir nombres a mayusculas.
-------------------------------
  Nombre  Edad Categoria_Edad
0    ANA    26          Joven
1    PAO    31         Adulto
2   LALO    36         Adulto
3    ANA    26          Joven
```

Agrupación y Agregación de Datos en Pandas.

- En este apartado aprenderemos a agrupar, resumir y analizar datos usando funciones como groupby(), agg() y operaciones estadísticas.
- El método gropuby() permite agrupar datos basado en una o más columnas

In [31]:
```
import pandas as pd

# Crear un DataFrame
datos = {
```

```
    "Producto": ["Laptop", "Mouse", "Laptop", "Teclado", "Mouse"],
    "Categoria": ["Electrónica", "Accesorios", "Electrónica", "Accesorios", "Accesc
    "Precio": [1000, 50, 1200, 80, 55]
}
print("\nDataFrame")
print(datos)

df = pd.DataFrame(datos)

# Agrupar por "Producto" y obtener el precio promedio
print("\nAgrupar por producto y obtener el precio promedio")
agrupado = df.groupby("Producto")["Precio"].mean()
print(agrupado)
```

```
DataFrame
{'Producto': ['Laptop', 'Mouse', 'Laptop', 'Teclado', 'Mouse'], 'Categoria': ['Ele
ctrónica', 'Accesorios', 'Electrónica', 'Accesorios', 'Accesorios'], 'Precio': [10
00, 50, 1200, 80, 55]}

Agrupar por producto y obtener el precio promedio
Producto
Laptop     1100.0
Mouse        52.5
Teclado      80.0
Name: Precio, dtype: float64
```

In [29]:
```
import pandas as pd

df = pd.DataFrame({
    "Departamento": ["Ventas", "Ventas", "IT", "IT", "RRHH", "RRHH", "IT"],
    "Empleado": ["Ana", "Luis", "Carlos", "María", "Sofía", "Pedro", "Elena"],
    "Salario": [5000, 4500, 6000, 5200, 4800, 4700, 6100]
})

# Agrupar por "Departamento" y calcular el salario promedio
df_grouped = df.groupby("Departamento")["Salario"].mean()
print(df_grouped)
```

```
Departamento
IT        5766.666667
RRHH      4750.000000
Ventas    4750.000000
Name: Salario, dtype: float64
```

In [32]:
```
print("\nAgrupar por multiples columnas")
agrupado = df.groupby(["Categoria", "Producto"])["Precio"].mean()
print(agrupado)
```

```
Agrupar por multiples columnas
Categoria    Producto
Accesorios   Mouse         52.5
             Teclado       80.0
Electrónica  Laptop      1100.0
Name: Precio, dtype: float64
```

Funciones de agregación (sum(), mean(), count(), agg())

- Podemos aplicar funciones de agregación para obtener estadísticas sobre los datos agrupados.

In [35]:
```
print("\nContar productos por categoría.")
conteo =  df.groupby("Categoria")["Producto"].count()
print(conteo)
```

```
print("\nAplicando multiples funciones con agg.")
resumen = df.groupby("Categoria")["Precio"].agg(["sum", "mean", "max", "min"])
print(resumen)
```

```
Contar productos por categoría.
Categoria
Accesorios     3
Electrónica    2
Name: Producto, dtype: int64

Aplicando multiples funciones con agg.
              sum         mean   max   min
Categoria
Accesorios    185    61.666667    80    50
Electrónica  2200  1100.000000  1200  1000
```

Agrupar y filtrar datos con filter()

In [30]:
```
df_filtrado = df.groupby("Departamento").filter(lambda x: len(x) > 2)
print(df_filtrado)
```

```
  Departamento Empleado  Salario
2           IT   Carlos     6000
3           IT    María     5200
6           IT    Elena     6100
```

Obtener estadísticos generales con describe()

- Podemos obtener un resumen estadístico por grupo.

In [31]:
```
df_grouped = df.groupby("Departamento")["Salario"].describe()
print(df_grouped)
```

```
              count         mean         std     min     25%     50%     75%  \
Departamento
IT              3.0  5766.666667  493.288286  5200.0  5600.0  6000.0  6050.0
RRHH            2.0  4750.000000   70.710678  4700.0  4725.0  4750.0  4775.0
Ventas          2.0  4750.000000  353.553391  4500.0  4625.0  4750.0  4875.0

                max
Departamento
IT           6100.0
RRHH         4800.0
Ventas       5000.0
```

Aplicación de transform() y apply() en Agrupaciones.

In [ ]:
```
print("\nCalculo de porcentaje del precio respecto al total por categoria")
df["Total_Categoria"] = df.groupby("Categoria")["Precio"].transform("sum")
df["Porcentaje"] = (df["Precio"] / df["Total_Categoria"]) * 100
print(df)
```

```
Calculo de el porcentaje del precio respecto al total por categoria
  Producto    Categoria  Precio  Total_Categoria  Porcentaje
0   Laptop  Electrónica    1000             2200   45.454545
1    Mouse   Accesorios      50              185   27.027027
2   Laptop  Electrónica    1200             2200   54.545455
3  Teclado   Accesorios      80              185   43.243243
4    Mouse   Accesorios      55              185   29.729730
```

Combinación y fusión de DataFrames en Pandas

- En este módulo aprenderemos a unir, concatenar y fusionar DataFrames utilizando funciones como merge(), concat() y join()

Concatenación vertical (Apilado de Datos)

In [37]:
```
import pandas as pd

# Crear dos DataFrames
df1 = pd.DataFrame({"ID": [1, 2, 3], "Nombre": ["Ana", "Luis", "Carlos"]})
df2 = pd.DataFrame({"ID": [4, 5], "Nombre": ["Marta", "Pedro"]})

# Concatenación vertical
df_concatenado = pd.concat([df1, df2], ignore_index=True)
print(df_concatenado)
```

```
   ID  Nombre
0   1     Ana
1   2    Luis
2   3  Carlos
3   4   Marta
4   5   Pedro
```

Concatenación horizontal (Añadir columnas)

In [38]:
```
df3 = pd.DataFrame({"ID": [1, 2, 3], "Edad": [25, 30, 35]})

# Concatenación horizontal
df_combinado = pd.concat([df1, df3], axis=1)
print(df_combinado)
```

```
   ID  Nombre  ID  Edad
0   1     Ana   1    25
1   2    Luis   2    30
2   3  Carlos   3    35
```

Fusión de DataFrames con merge()

- La función merge() es más flexible y permite combinar DataFrames con en SQL(INNER JOIN, LEFT JOIN, RIGHT JOIN, OUTER JOIN).

In [39]:
```
df1 = pd.DataFrame({"ID": [1, 2, 3], "Nombre": ["Ana", "Luis", "Carlos"]})
df2 = pd.DataFrame({"ID": [1, 3, 4], "Edad": [25, 35, 40]})

# Fusionar por la columna "ID"
df_merge = pd.merge(df1, df2, on="ID", how="inner")
print(df_merge)
```

```
   ID  Nombre  Edad
0   1     Ana    25
1   3  Carlos    35
```

LEFT JOIN (Mantener todos los datos de la izquierda)

In [40]:
```
df_merge = pd.merge(df1, df2, on="ID", how="left")
print(df_merge)
```

```
   ID  Nombre  Edad
0   1     Ana  25.0
1   2    Luis   NaN
2   3  Carlos  35.0
```

Unión de DataFrames cono join()

- El método join() se usa cuando queremos unir DataFrames basados en el índice.

In [41]:
```
print("\nUnir los DataFrames por el indice.")
df1 = pd.DataFrame({"Nombre": ["Ana", "Luis", "Carlos"]}, index=[1, 2, 3])
df2 = pd.DataFrame({"Edad": [25, 30, 35]}, index=[1, 2, 3])

df_unido = df1.join(df2)
print(df_unido)
```

```
Unir los DataFrames por el indice.
   Nombre  Edad
1     Ana    25
2    Luis    30
3  Carlos    35
```

RIGTH JOIN (Mantener todos los datos de la derecha)

- Este tipo de fusión mantiene todas las filas de la derecha, aunque algunas no tengan coincidencia en la izquierda.

In [42]:
```
df1 = pd.DataFrame({"ID": [1, 2, 3], "Nombre": ["Ana", "Luis", "Carlos"]})
df2 = pd.DataFrame({"ID": [1, 3, 4], "Edad": [25, 35, 40]})

df_merge = pd.merge(df1, df2, on="ID", how="right")
print(df_merge)
```

```
   ID  Nombre  Edad
0   1     Ana    25
1   3  Carlos    35
2   4     NaN    40
```

OUTER JOIN (Unión completa de los datos)

- Aquí se combinan todos los datos de ambos DaraFrames, incluso si no tienen coincidencias.

In [43]:
```
df_merge = pd.merge(df1, df2, on="ID", how="outer")
print(df_merge)
```

```
   ID  Nombre  Edad
0   1     Ana  25.0
1   2    Luis   NaN
2   3  Carlos  35.0
3   4     NaN  40.0
```

Concatenar DataFrames con diferentes columnas

- Si los DataFrames tienen columnas distintas concat() rellena con NaN los valores faltantes.

In [44]:
```
df1 = pd.DataFrame({"ID": [1, 2], "Nombre": ["Ana", "Luis"]})
df2 = pd.DataFrame({"ID": [3, 4], "Edad": [25, 30]})

df_concatenado = pd.concat([df1, df2], ignore_index=True)
print(df_concatenado)
```

```
   ID Nombre  Edad
0   1    Ana   NaN
1   2   Luis   NaN
2   3    NaN  25.0
3   4    NaN  30.0
```

Fusionar con diferentes nombres de columnas (left_on, right_on)

- Podemos unir DatasFrames que no tienen el mismo nombre de columna para la clave

In [45]:
```
df_clientes = pd.DataFrame({"ID_Cliente": [1, 2, 3], "Nombre": ["Ana", "Luis", "Car
df_compras = pd.DataFrame({"ID": [1, 3, 4], "Producto": ["Laptop", "Mouse", "Teclac

df_merge = pd.merge(df_clientes, df_compras, left_on="ID_Cliente", right_on="ID", h
print(df_merge)
```

```
   ID_Cliente  Nombre   ID Producto
0           1     Ana  1.0   Laptop
1           2    Luis  NaN      NaN
2           3  Carlos  3.0    Mouse
```

Unir multiples DataFrames con reduce()

- Cuando necesitamos unir varios DataFrames, podemos hacerlo con reduce()

In [46]:
```
from functools import reduce

df1 = pd.DataFrame({"ID": [1, 2, 3], "Nombre": ["Ana", "Luis", "Carlos"]})
df2 = pd.DataFrame({"ID": [1, 3, 4], "Edad": [25, 35, 40]})
df3 = pd.DataFrame({"ID": [1, 2, 4], "Salario": [2000, 2500, 3000]})

dfs = [df1, df2, df3]

df_final = reduce(lambda left, right: pd.merge(left, right, on="ID", how="outer"),
print(df_final)
```

```
   ID  Nombre  Edad  Salario
0   1     Ana  25.0   2000.0
1   2    Luis   NaN   2500.0
2   3  Carlos  35.0      NaN
3   4     NaN  40.0   3000.0
```

Manejo de Datos faltantes en Pandas

- En este módulo aprenderemos a manejar valores NaN (valores nulos o faltantes) en un DataFrame.
- Al trabajar con datos reales, es común encontrar valores ausentes, por lo que es importante saber cómo detectarlos, eliminarlos o reemplazarlos.

Detección de Datos faltantes.

- Para identificar valores faltantes en un DataFrame, usamos isna() o isnull() (ambas hacen lo mismo)

Identificar valores nulos en un DataFrame

- isna() devuelve un DataFrame de True/false indicando dónde hay valores nulos.
- sum() cuenta la cantidad de valores nulos en cada columna.

In [2]:
```
import pandas as pd
import numpy as np

# Crear un DataFrame con valores faltantes
df = pd.DataFrame({
    "Nombre": ["Ana", "Luis", "Carlos", np.nan, "Marta"],
    "Edad": [25, np.nan, 35, 40, np.nan],
    "Ciudad": ["Mexico", "Canada", "EU", "Panama", np.nan]
})

# Mostrar el DataFrame
print(df)

# Detectar valores nulos
print(df.isna())

# Contar valores nulos por columna
print(df.isna().sum())
```

```
   Nombre  Edad  Ciudad
0     Ana  25.0  Mexico
1    Luis   NaN  Canada
2  Carlos  35.0      EU
3     NaN  40.0  Panama
4   Marta   NaN     NaN
   Nombre   Edad  Ciudad
0   False  False   False
1   False   True   False
2   False  False   False
3    True  False   False
4   False   True    True
Nombre    1
Edad      2
Ciudad    1
dtype: int64
```

Eliminación de datos faltantes (dropna())

- Podemos eliminar filas o columnas con datos nulos usando dropna()
- Eliminar filas con valores nulos.

In [3]:
```
df_sin_nulos = df.dropna()
print(df_sin_nulos)
```

```
   Nombre  Edad  Ciudad
0     Ana  25.0  Mexico
2  Carlos  35.0      EU
```

Eliminar columnas con valores nulos.

In [4]:
```
df_sin_columnas_nulas = df.dropna(axis=1)
print(df_sin_columnas_nulas)
```

```
Empty DataFrame
Columns: []
Index: [0, 1, 2, 3, 4]
```

Relleno de datos faltantes (fillna())

- En lugar de eliminar datos, podemos reemplazar valores nulos con fillna()
- Rellenar valores nulos con un valor especifico.

In [5]:
```
df_rellenado = df.fillna("Desconocido")
print(df_rellenado)
```

```
        Nombre         Edad       Ciudad
0          Ana         25.0       Mexico
1         Luis  Desconocido       Canada
2       Carlos         35.0           EU
3  Desconocido         40.0       Panama
4        Marta  Desconocido  Desconocido
```

Rellenar valores nulos con la media de la columna.

In [6]:
```
media_edad = df["Edad"].mean()
df["Edad"] = df["Edad"].fillna(media_edad)
print(df)
```

```
   Nombre       Edad  Ciudad
0     Ana  25.000000  Mexico
1    Luis  33.333333  Canada
2  Carlos  35.000000      EU
3     NaN  40.000000  Panama
4   Marta  33.333333     NaN
```

Interpolación de datos.

- Si los datos siguen una tendencia, interpolate() puede estimar valores faltantes.
- Interpolar valores numéricos.

In [7]:
```
df_numerico = pd.DataFrame({"Año": [2000, 2001, 2002, 2003, 2004],
                            "Ventas": [100, np.nan, 200, np.nan, 400]})

df_interpolado = df_numerico.interpolate()
print(df_interpolado)
```

```
    Año  Ventas
0  2000   100.0
1  2001   150.0
2  2002   200.0
3  2003   300.0
4  2004   400.0
```

Manejo de fechas y tiempos en Pandas

- El manejo de fechas es crucial en análisis de datos, especialmente en series temporales.
- Pandas proporciona herramientas poderosas para trabajar con fechas, como pd.to_datetime(), dt y resample().

Convertir fechas con pd.to_datetime()

In [22]:
```
import pandas as pd

df = pd.DataFrame({
    "fecha" : ["2025-01-01", "2025-02-01", "2025-03-01"],
    "ventas": [100, 150, 200]
})

df["fecha"] = pd.to_datetime(df["fecha"])
print(df.dtypes)
print("Ahora fecha es de tipo datetime64, lo que permite hacer operaciones avanzada
```

```
fecha     datetime64[ns]
ventas             int64
dtype: object
Ahora fecha es de tipo datetime64, lo que permite hacer operaciones avanzadas
```

Extracción de componentes dde fechas.(.dt)

- Podemos extraer año, mes, dia, etc.

In [12]:
```
df["Año"] = df["fecha"].dt.year
df["Mes"] = df["fecha"].dt.month
df["dia"] = df["fecha"].dt.day
df["Dia_Semana"] = df["fecha"].dt.day_name()
print(df)
```

```
       fecha  ventas   Año  Mes  dia Dia_Semana
0 2025-01-01     100  2025    1    1  Wednesday
1 2025-02-01     150  2025    2    1   Saturday
2 2025-03-01     200  2025    3    1   Saturday
```

Creación de rano de fechas (pd.date_range())

- Si necesitamos generar una serie de fechas pd.date_range() nos ayuda.
- Generar un rango de fechas diaria.

In [13]:
```
rango_fechas = pd.date_range(start="2025-02-02", end="2025-03-03", freq="D")
print(rango_fechas)
```

```
DatetimeIndex(['2025-02-02', '2025-02-03', '2025-02-04', '2025-02-05',
               '2025-02-06', '2025-02-07', '2025-02-08', '2025-02-09',
               '2025-02-10', '2025-02-11', '2025-02-12', '2025-02-13',
               '2025-02-14', '2025-02-15', '2025-02-16', '2025-02-17',
               '2025-02-18', '2025-02-19', '2025-02-20', '2025-02-21',
               '2025-02-22', '2025-02-23', '2025-02-24', '2025-02-25',
               '2025-02-26', '2025-02-27', '2025-02-28', '2025-03-01',
               '2025-03-02', '2025-03-03'],
              dtype='datetime64[ns]', freq='D')
```

Operaciones con fechas.

- Podemos calcular diferencias, agregar días y más

In [14]:
```
df["Dias desde inicio"] = (df["fecha"] - df["fecha"].min()).dt.days
print(df)
```

```
       fecha  ventas   Año  Mes  dia Dia_Semana  Dias desde inicio
0 2025-01-01     100  2025    1    1  Wednesday                  0
1 2025-02-01     150  2025    2    1   Saturday                 31
2 2025-03-01     200  2025    3    1   Saturday                 59
```

Re-muestreo de datos temporales (resample())

- Podemos agrupar datos por días, semanas o meses con resample()

In [23]:
```
df.set_index("fecha", inplace=True)
df_mensual = df.resample("M").sum()
print(df_mensual)
```

```
            ventas
fecha
2025-01-31     100
2025-02-28     150
2025-03-31     200
```

```
C:\Users\Lalo\AppData\Local\Temp\ipykernel_20152\2306358148.py:2: FutureWarning:
'M' is deprecated and will be removed in a future version, please use 'ME' instea
d.
  df_mensual = df.resample("M").sum()
```

Filtrar datos por fechas.

- Podemos seleccionar datos en un rango de fechas.

In [24]:
```
df = pd.DataFrame({
    "Fecha": pd.date_range(start="2024-01-01", periods=10, freq="D"),
    "Ventas": [100, 150, 120, 180, 200, 140, 160, 180, 220, 190]
})

# Filtrar datos entre el 3 y el 7 de enero
filtro = (df["Fecha"] >= "2024-01-03") & (df["Fecha"] <= "2024-01-07")
df_filtrado = df[filtro]
print(df_filtrado)
```

```
       Fecha  Ventas
2 2024-01-03     120
3 2024-01-04     180
4 2024-01-05     200
5 2024-01-06     140
6 2024-01-07     160
```

Reemplazar el formato fecha.

- Podemos cambiar el formato de fechas con .dt.strftime()

%d/%m/%y da formato día/mes/año.

%Y da formato año completo.

%Y-%m-%d da formato 2025-02-02.

%B %d, %y da formato Febrero 13, 2025.

%A Monday es dia de la semana.

In [25]:
```
df["Fecha Formateada"] = df["Fecha"].dt.strftime("%d/%m/%Y")
print(df[["Fecha", "Fecha Formateada"]])
```

```
       Fecha Fecha Formateada
0 2024-01-01       01/01/2024
1 2024-01-02       02/01/2024
2 2024-01-03       03/01/2024
3 2024-01-04       04/01/2024
4 2024-01-05       05/01/2024
5 2024-01-06       06/01/2024
6 2024-01-07       07/01/2024
7 2024-01-08       08/01/2024
8 2024-01-09       09/01/2024
9 2024-01-10       10/01/2024
```

Análisis exploratorio de datos en Pandas (EDA)

- El análisis exploratorio de datos (EDA, Exploratory Data Analysis) es un proceso clave en ciencia de datos. Permite comprender, limpiar y visualizar la información antes de aplicar modelos o tomar decisiones.
- Pandas ofrece muchas herramientas para realizar EDA de manera eficiente.

Cargar datos y obtener información general.

- Antes de analizar datos, necesitamos cargarlos y revisar su estructura.

Cargar un dataset y obtener información básica.

- Este dataset que vamos a cargar para hacer EDA lo tenemos de forma local y fue descargado desde Kaggle
- link https://www.kaggle.com/datasets/sameerk2004/space-missions-dataset
- Pueden hacer uso de cualquier dataset que sea de su agrado.

In [33]:
```
import pandas as pd

# Cargar un dataset desde un archivo CSV
df = pd.read_csv("space_missions_dataset.csv")

# Información general sobre las columnas y tipos de datos
print("Información General sobre el dataset")
print(df.info())
```

```
Información General sobre el dataset
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 15 columns):
 #   Column                            Non-Null Count  Dtype  
---  ------                            --------------  -----  
 0   Mission ID                        500 non-null    object 
 1   Mission Name                      500 non-null    object 
 2   Launch Date                       500 non-null    object 
 3   Target Type                       500 non-null    object 
 4   Target Name                       500 non-null    object 
 5   Mission Type                      500 non-null    object 
 6   Distance from Earth (light-years) 500 non-null    float64
 7   Mission Duration (years)          500 non-null    float64
 8   Mission Cost (billion USD)        500 non-null    float64
 9   Scientific Yield (points)         500 non-null    float64
 10  Crew Size                         500 non-null    int64  
 11  Mission Success (%)               500 non-null    float64
 12  Fuel Consumption (tons)           500 non-null    float64
 13  Payload Weight (tons)             500 non-null    float64
 14  Launch Vehicle                    500 non-null    object 
dtypes: float64(7), int64(1), object(7)
memory usage: 58.7+ KB
None
```

Inspección de los datos.

In [36]:
```
print("\nVamos a mostrar las primeros 5 filas")
df.head()
```

```
Vamos a mostrar las primeros 5 filas
```

Out[36]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	Sci (p
0	MSN-0001	Mission-1	2025-01-01	Star	Titan	Colonization	7.05	5.2	526.68	
1	MSN-0002	Mission-2	2025-01-08	Exoplanet	Betelgeuse	Colonization	41.76	23.0	234.08	
2	MSN-0003	Mission-3	2025-01-15	Asteroid	Mars	Exploration	49.22	28.8	218.68	
3	MSN-0004	Mission-4	2025-01-22	Exoplanet	Titan	Colonization	26.33	17.8	232.89	
4	MSN-0005	Mission-5	2025-01-29	Exoplanet	Proxima b	Mining	8.67	9.2	72.14	

In [37]:
```
print("\nVamos a mostrar las ultimas 5 filas")
df.tail()
```

```
Vamos a mostrar las ultimas 5 filas
```

Out[37]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	Sc (
495	MSN-0496	Mission-496	2034-06-28	Planet	Betelgeuse	Colonization	48.26	25.3	274.82	
496	MSN-0497	Mission-497	2034-07-05	Asteroid	Betelgeuse	Exploration	0.35	4.1	379.71	
497	MSN-0498	Mission-498	2034-07-12	Planet	Ceres	Exploration	47.60	26.6	296.45	
498	MSN-0499	Mission-499	2034-07-19	Planet	Betelgeuse	Research	31.99	18.0	457.38	
499	MSN-0500	Mission-500	2034-07-26	Planet	Io	Exploration	43.41	23.5	449.40	

In [38]:
```
print("\nVamos a mostrar 5 filas de forma aleatorias")
df.sample(5)
```

```
Vamos a mostrar 5 filas de forma aleatorias
```

Out[38]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	Scier (po
361	MSN-0362	Mission-362	2031-12-03	Star	Proxima b	Research	6.72	7.9	479.66	
474	MSN-0475	Mission-475	2034-02-01	Asteroid	Titan	Mining	33.22	20.1	81.24	
46	MSN-0047	Mission-47	2025-11-19	Moon	Io	Colonization	29.79	17.2	426.74	
220	MSN-0221	Mission-221	2029-03-21	Moon	Proxima b	Mining	35.45	22.5	228.78	
110	MSN-0111	Mission-111	2027-02-10	Planet	Mars	Exploration	27.02	17.0	47.56	

In [39]:
```
print("\nVamos a ver la cantidad de columnas")
df.shape
```

Out[39]:
```
Vamos a ver la cantidad de columnas
(500, 15)
```

In [40]:
```
print("\nListar nombres de las columnas")
df.columns
```

Out[40]:
```
Listar nombres de las columnas
Index(['Mission ID', 'Mission Name', 'Launch Date', 'Target Type',
       'Target Name', 'Mission Type', 'Distance from Earth (light-years)',
       'Mission Duration (years)', 'Mission Cost (billion USD)',
       'Scientific Yield (points)', 'Crew Size', 'Mission Success (%)',
       'Fuel Consumption (tons)', 'Payload Weight (tons)', 'Launch Vehicle'],
      dtype='object')
```

In [41]:
```
print("\nVer indices del dataframe")
df.index
```

Out[41]:
```
Ver indices del dataframe
RangeIndex(start=0, stop=500, step=1)
```

In [42]:
```
print("\nListar tipos de datos de las columnas")
df.dtypes
```

```
Listar tipos de datos de las columnas
```

Out[42]:
```
Mission ID                          object
Mission Name                        object
Launch Date                         object
Target Type                         object
Target Name                         object
Mission Type                        object
Distance from Earth (light-years)  float64
Mission Duration (years)           float64
Mission Cost (billion USD)         float64
Scientific Yield (points)          float64
Crew Size                            int64
Mission Success (%)                float64
Fuel Consumption (tons)            float64
Payload Weight (tons)              float64
Launch Vehicle                      object
dtype: object
```

In [47]:
```
print("\nInformación general sobre el dataframe")
df.info()
```

```
Información general sobre el dataframe
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 15 columns):
 #   Column                           Non-Null Count  Dtype
---  ------                           --------------  -----
 0   Mission ID                       500 non-null    object
 1   Mission Name                     500 non-null    object
 2   Launch Date                      500 non-null    object
 3   Target Type                      500 non-null    object
 4   Target Name                      500 non-null    object
 5   Mission Type                     500 non-null    object
 6   Distance from Earth (light-years)  500 non-null    float64
 7   Mission Duration (years)         500 non-null    float64
 8   Mission Cost (billion USD)       500 non-null    float64
 9   Scientific Yield (points)        500 non-null    float64
 10  Crew Size                        500 non-null    int64
 11  Mission Success (%)              500 non-null    float64
 12  Fuel Consumption (tons)          500 non-null    float64
 13  Payload Weight (tons)            500 non-null    float64
 14  Launch Vehicle                   500 non-null    object
dtypes: float64(7), int64(1), object(7)
memory usage: 58.7+ KB
```

In [ ]:
```
print("\nEstadísticas basics de columnas numéricas")
df.describe()
```

```
Estadisticas basics de columnas numericas
```

Out[ ]:

	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	Scientific Yield (points)	Crew Size	Mission Success (%)	Fuel Consumption (tons)	P
count	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000	500.000000	500.
mean	25.483060	15.736800	277.300280	55.223400	50.118000	92.616600	2543.522140	50.
std	14.942128	7.578316	141.137422	26.446232	27.660989	9.391094	1492.964489	28.
min	0.350000	1.400000	13.320000	10.000000	1.000000	66.000000	18.060000	1.
25%	11.750000	8.900000	149.960000	33.775000	27.000000	85.500000	1177.315000	25.
50%	26.185000	16.400000	282.170000	54.400000	50.000000	98.600000	2597.985000	50.
75%	38.570000	22.200000	399.995000	79.025000	74.000000	100.000000	3859.355000	74.
max	49.900000	29.500000	538.320000	99.800000	99.000000	100.000000	5018.600000	99.

In [ ]:
```
print("\nEstadísticas de todas las columnas")
df.describe(include="all")
```

```
Estadisticas de todas las columnas
```

Out[ ]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)
count	500	500	500	500	500	500	500.000000	500.000000	500.000000
unique	500	500	500	5	7	4	NaN	NaN	NaN
top	MSN-0001	Mission-1	2025-01-01	Star	Proxima b	Research	NaN	NaN	NaN
freq	1	1	1	112	81	132	NaN	NaN	NaN
mean	NaN	NaN	NaN	NaN	NaN	NaN	25.483060	15.736800	277.300280
std	NaN	NaN	NaN	NaN	NaN	NaN	14.942128	7.578316	141.137422
min	NaN	NaN	NaN	NaN	NaN	NaN	0.350000	1.400000	13.320000
25%	NaN	NaN	NaN	NaN	NaN	NaN	11.750000	8.900000	149.960000
50%	NaN	NaN	NaN	NaN	NaN	NaN	26.185000	16.400000	282.170000
75%	NaN	NaN	NaN	NaN	NaN	NaN	38.570000	22.200000	399.995000
max	NaN	NaN	NaN	NaN	NaN	NaN	49.900000	29.500000	538.320000

In [46]:
```
print("\nVer el consumo de la memoria")
df.memory_usage
```

```
Ver el consumo de la memoria
```

Out[46]:

```
<bound method DataFrame.memory_usage of     Mission ID Mission Name Launch Date Ta
rget Type Target Name  Mission Type  \
0     MSN-0001    Mission-1  2025-01-01        Star       Titan  Colonization
1     MSN-0002    Mission-2  2025-01-08   Exoplanet  Betelgeuse  Colonization
2     MSN-0003    Mission-3  2025-01-15    Asteroid        Mars   Exploration
3     MSN-0004    Mission-4  2025-01-22   Exoplanet       Titan  Colonization
4     MSN-0005    Mission-5  2025-01-29   Exoplanet   Proxima b        Mining
..         ...          ...         ...         ...         ...           ...
495   MSN-0496  Mission-496  2034-06-28      Planet  Betelgeuse  Colonization
496   MSN-0497  Mission-497  2034-07-05    Asteroid  Betelgeuse   Exploration
497   MSN-0498  Mission-498  2034-07-12      Planet       Ceres   Exploration
498   MSN-0499  Mission-499  2034-07-19      Planet  Betelgeuse      Research
499   MSN-0500  Mission-500  2034-07-26      Planet          Io   Exploration

     Distance from Earth (light-years)  Mission Duration (years)  \
0                                 7.05                       5.2
1                                41.76                      23.0
2                                49.22                      28.8
3                                26.33                      17.8
4                                 8.67                       9.2
..                                 ...                       ...
495                              48.26                      25.3
496                               0.35                       4.1
497                              47.60                      26.6
498                              31.99                      18.0
499                              43.41                      23.5

     Mission Cost (billion USD)  Scientific Yield (points)  Crew Size  \
0                        526.68                       64.3         21
1                        234.08                       84.4         72
2                        218.68                       98.6         16
3                        232.89                       36.0         59
4                         72.14                       96.5         31
..                          ...                        ...        ...
495                      274.82                       91.2         64
496                      379.71                       82.6         61
497                      296.45                       98.6         29
498                      457.38                       77.9         39
499                      449.40                       45.4         88

     Mission Success (%)  Fuel Consumption (tons)  Payload Weight (tons)  \
0                  100.0                   731.88                  99.78
1                   89.6                  4197.41                  45.72
2                   98.6                  4908.00                  36.12
3                   90.0                  2569.05                  40.67
4                   73.2                   892.76                  12.40
..                   ...                      ...                    ...
495                 96.2                  4837.16                  44.97
496                100.0                    62.59                  67.88
497                100.0                  4794.01                  51.38
498                100.0                  3102.16                  86.28
499                100.0                  4302.93                  86.74

    Launch Vehicle
0              SLS
1         Starship
2         Starship
3         Starship
4         Starship
..             ...
495       Ariane 6
496            SLS
497   Falcon Heavy
498            SLS
```

```
499   Falcon Heavy

[500 rows x 15 columns]>
```

Manejo de valores nulos

In [50]:
```
print("\nSe muestra el numero de valores nulos en cada columna.")
df.isnull().sum()
```

Out[50]:
```
Se muestra el numero de valores nulos en cada columna.
Mission ID                          0
Mission Name                        0
Launch Date                         0
Target Type                         0
Target Name                         0
Mission Type                        0
Distance from Earth (light-years)   0
Mission Duration (years)            0
Mission Cost (billion USD)          0
Scientific Yield (points)           0
Crew Size                           0
Mission Success (%)                 0
Fuel Consumption (tons)             0
Payload Weight (tons)               0
Launch Vehicle                      0
dtype: int64
```

-Podemos eliminar calores nulos. pero como podemos ver este dataframe esta completo asi que solo comparto las instrucciones en caso de que un data si tenga valores nulos.

- df_sin_nulos = df.dropna()
- df_sin_columnas_nulas = df.dropna(axis=1)

Estas lineas son para rellenar valores faltantes.

- df["Target Type"].fillna(df["Target Type"].mean(), inplace=True) # Rellenar con la media
- df["Mission Type "].fillna("Desconocido", inplace=True) # Rellenar con un valor fijo

Analisis de frecuencias.

- Podemos contar cuantas veces aparece cada valor en una columna categorica.

In [51]:
```
print(df["Mission Name"].value_counts())
```

```
Mission Name
Mission-1      1
Mission-330    1
Mission-343    1
Mission-342    1
Mission-341    1
              ..
Mission-162    1
Mission-161    1
Mission-160    1
Mission-159    1
Mission-500    1
Name: count, Length: 500, dtype: int64
```

In [52]:
```
print(df["Mission Duration (years)"].value_counts())
```

```
Mission Duration (years)
26.6    7
19.0    6
25.8    6
8.9     6
26.1    6
       ..
8.1     1
29.5    1
18.8    1
12.6    1
17.3    1
Name: count, Length: 231, dtype: int64
```

Instrucciones completas para trabajar con valores nulos.

- df.isnull().sum() # Contar valores nulos en cada columna.
- df.notnull().sum() # Contar valores NO nulos.
- df.dropna() # Eliminar filas con valores nulos.
- df.dropna(axis=1) # Eliminar columnas con valores nulos.
- df.fillna(0) # Reemplazar valores nulos con 0.
- df.fillna(df.mean()) # Rellenar con la media.
- df.fillna(df.median()) # Rellenar con la mediana.
- df.fillna(method="ffill") # Rellenar con el valor anterior.
- df.fillna(method="bfill") # Rellenar con el siguiente valor.
- df.interpolate() # Rellenar valores nulos interpolando.

Buscaremos un dataframe que tenga valores nulos y asi poder probar esta lista de instrucciones.

Duplicados

In [55]:
```
print("\nConteo de filas duplicadas")
df.duplicated().sum()

print("\nEliminar duplicados")
df.duplicated().sum()

print("\nEliminar duplicados en una columna")
df.drop_duplicates(subset=["Target Name"])
```

```
Conteo de filas duplicadas

Eliminar duplicados

Eliminar duplicados en una columna
```

Out[55]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	Sc
0	MSN-0001	Mission-1	2025-01-01	Star	Titan	Colonization	7.05	5.2	526.68	
1	MSN-0002	Mission-2	2025-01-08	Exoplanet	Betelgeuse	Colonization	41.76	23.0	234.08	
2	MSN-0003	Mission-3	2025-01-15	Asteroid	Mars	Exploration	49.22	28.8	218.68	
4	MSN-0005	Mission-5	2025-01-29	Exoplanet	Proxima b	Mining	8.67	9.2	72.14	
5	MSN-0006	Mission-6	2025-02-05	Moon	Ceres	Colonization	13.69	8.8	452.42	
15	MSN-0016	Mission-16	2025-04-16	Moon	Io	Exploration	0.65	3.1	495.63	
21	MSN-0022	Mission-22	2025-05-28	Exoplanet	Europa	Mining	33.29	18.9	201.81	

In [91]:
```
df = pd.read_csv("space_missions_dataset.csv")
```

Filtrado de datos.

In [92]:
```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 15 columns):
 #   Column                           Non-Null Count  Dtype  
---  ------                           --------------  -----  
 0   Mission ID                       500 non-null    object 
 1   Mission Name                     500 non-null    object 
 2   Launch Date                      500 non-null    object 
 3   Target Type                      500 non-null    object 
 4   Target Name                      500 non-null    object 
 5   Mission Type                     500 non-null    object 
 6   Distance from Earth (light-years)  500 non-null    float64
 7   Mission Duration (years)         500 non-null    float64
 8   Mission Cost (billion USD)       500 non-null    float64
 9   Scientific Yield (points)        500 non-null    float64
 10  Crew Size                        500 non-null    int64  
 11  Mission Success (%)              500 non-null    float64
 12  Fuel Consumption (tons)          500 non-null    float64
 13  Payload Weight (tons)            500 non-null    float64
 14  Launch Vehicle                   500 non-null    object 
dtypes: float64(7), int64(1), object(7)
memory usage: 58.7+ KB
```

In [93]:
```
print("\nFiltrar valores mayores a 100")
df[df["Crew Size"] > 50]
```

```
Filtrar valores mayores a 100
```

Out[93]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	S
1	MSN-0002	Mission-2	2025-01-08	Exoplanet	Betelgeuse	Colonization	41.76	23.0	234.08	
3	MSN-0004	Mission-4	2025-01-22	Exoplanet	Titan	Colonization	26.33	17.8	232.89	
6	MSN-0007	Mission-7	2025-02-12	Asteroid	Ceres	Research	1.02	5.0	220.38	
8	MSN-0009	Mission-9	2025-02-26	Asteroid	Betelgeuse	Exploration	5.98	4.4	361.35	
11	MSN-0012	Mission-12	2025-03-19	Asteroid	Mars	Research	27.75	15.5	38.80	
...	...	...	...	...	...	...	...	...	...	
490	MSN-0491	Mission-491	2034-05-24	Planet	Proxima b	Research	15.88	10.0	112.99	
492	MSN-0493	Mission-493	2034-06-07	Star	Io	Colonization	2.17	3.4	202.50	
495	MSN-0496	Mission-496	2034-06-28	Planet	Betelgeuse	Colonization	48.26	25.3	274.82	
496	MSN-0497	Mission-497	2034-07-05	Asteroid	Betelgeuse	Exploration	0.35	4.1	379.71	
499	MSN-0500	Mission-500	2034-07-26	Planet	Io	Exploration	43.41	23.5	449.40	

249 rows × 15 columns

In [100…

```
print("\nFiltrar por misiones seleccionadas.")
misiones_seleccionadas = df[["Mission Name", "Launch Date"]]
print(misiones_seleccionadas)
```

```
Filtrar por misiones seleccionadas.
    Mission Name Launch Date
0      Mission-1  2025-01-01
1      Mission-2  2025-01-08
2      Mission-3  2025-01-15
3      Mission-4  2025-01-22
4      Mission-5  2025-01-29
..           ...         ...
495  Mission-496  2034-06-28
496  Mission-497  2034-07-05
497  Mission-498  2034-07-12
498  Mission-499  2034-07-19
499  Mission-500  2034-07-26

[500 rows x 2 columns]
```

In [130…

```
print("\nFiltrado por misiones Exitosas")
misiones_exitosas = df[df["Mission Name"] == "Mission Success (%)"]
print("\n",misiones_exitosas)
```

```
Filtrado por misiones Exitosas

 Empty DataFrame
Columns: [Mission ID, Mission Name, Launch Date, Target Type, Target Name, Mission
Type, Distance from Earth (light-years), Mission Duration (years), Mission Cost (b
illion USD), Scientific Yield (points), Crew Size, Mission Success (%), Fuel Consu
mption (tons), Payload Weight (tons), Launch Vehicle]
Index: []
```

In [105…

```python
print("\nFiltrar por misiones lanzadas despues del 2000")
df["Launch Date"] = pd.to_datetime(df["Launch Date"])
misiones_post_2000 = df[df["Launch Date"].dt.year > 2000]
print(misiones_post_2000)
```

Filtrar por misiones lanzadas despues del 2000

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	\
0	MSN-0001	Mission-1	2025-01-01	Star	Titan	Colonization	
1	MSN-0002	Mission-2	2025-01-08	Exoplanet	Betelgeuse	Colonization	
2	MSN-0003	Mission-3	2025-01-15	Asteroid	Mars	Exploration	
3	MSN-0004	Mission-4	2025-01-22	Exoplanet	Titan	Colonization	
4	MSN-0005	Mission-5	2025-01-29	Exoplanet	Proxima b	Mining	
..	...	...	...	...	...	...	
495	MSN-0496	Mission-496	2034-06-28	Planet	Betelgeuse	Colonization	
496	MSN-0497	Mission-497	2034-07-05	Asteroid	Betelgeuse	Exploration	
497	MSN-0498	Mission-498	2034-07-12	Planet	Ceres	Exploration	
498	MSN-0499	Mission-499	2034-07-19	Planet	Betelgeuse	Research	
499	MSN-0500	Mission-500	2034-07-26	Planet	Io	Exploration	

	Distance from Earth (light-years)	Mission Duration (years)	\
0	7.05	5.2	
1	41.76	23.0	
2	49.22	28.8	
3	26.33	17.8	
4	8.67	9.2	
..	...	...	
495	48.26	25.3	
496	0.35	4.1	
497	47.60	26.6	
498	31.99	18.0	
499	43.41	23.5	

	Mission Cost (billion USD)	Scientific Yield (points)	Crew Size	\
0	526.68	64.3	21	
1	234.08	84.4	72	
2	218.68	98.6	16	
3	232.89	36.0	59	
4	72.14	96.5	31	
..	...	...	...	
495	274.82	91.2	64	
496	379.71	82.6	61	
497	296.45	98.6	29	
498	457.38	77.9	39	
499	449.40	45.4	88	

	Mission Success (%)	Fuel Consumption (tons)	Payload Weight (tons)	\
0	100.0	731.88	99.78	
1	89.6	4197.41	45.72	
2	98.6	4908.00	36.12	
3	90.0	2569.05	40.67	
4	73.2	892.76	12.40	
..	...	...	...	
495	96.2	4837.16	44.97	
496	100.0	62.59	67.88	
497	100.0	4794.01	51.38	
498	100.0	3102.16	86.28	
499	100.0	4302.93	86.74	

	Launch Vehicle
0	SLS
1	Starship
2	Starship
3	Starship
4	Starship
..	...
495	Ariane 6
496	SLS
497	Falcon Heavy
498	SLS

```
499   Falcon Heavy

[500 rows x 15 columns]
```

Trabajando con fechas.

- Vamos a trabajar con la columnas Launch Date ya que este data si contiene fechas.

In [112…

```
print("\nOrdenamos por el nombre la misión en descendente")
df_ordenado_mision = df.sort_values(by="Mission Name", ascending=False)
print(df_ordenado_mision)
```

Ordenamos por el nombre la misión en descendente

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	\
98	MSN-0099	Mission-99	2026-11-18	Moon	Titan	Colonization	
97	MSN-0098	Mission-98	2026-11-11	Moon	Io	Mining	
96	MSN-0097	Mission-97	2026-11-04	Exoplanet	Ceres	Colonization	
95	MSN-0096	Mission-96	2026-10-28	Asteroid	Europa	Exploration	
94	MSN-0095	Mission-95	2026-10-21	Planet	Europa	Exploration	
..	...	...	...	...	...	...	
101	MSN-0102	Mission-102	2026-12-09	Planet	Proxima b	Exploration	
100	MSN-0101	Mission-101	2026-12-02	Star	Proxima b	Exploration	
99	MSN-0100	Mission-100	2026-11-25	Planet	Ceres	Research	
9	MSN-0010	Mission-10	2025-03-05	Exoplanet	Betelgeuse	Colonization	
0	MSN-0001	Mission-1	2025-01-01	Star	Titan	Colonization	

	Distance from Earth (light-years)	Mission Duration (years)	\
98	16.02	9.3	
97	42.24	24.7	
96	43.12	26.2	
95	23.76	14.0	
94	47.22	27.1	
..	...	...	
101	29.85	16.2	
100	1.95	5.8	
99	41.46	25.4	
9	28.87	18.9	
0	7.05	5.2	

	Mission Cost (billion USD)	Scientific Yield (points)	Crew Size	\
98	283.51	10.8	89	
97	511.73	96.2	74	
96	217.39	29.0	43	
95	309.23	35.1	80	
94	433.28	82.4	76	
..	...	...	...	
101	360.96	84.6	68	
100	123.33	70.9	95	
99	310.28	99.8	20	
9	265.98	23.9	34	
0	526.68	64.3	21	

	Mission Success (%)	Fuel Consumption (tons)	Payload Weight (tons)	\
98	96.1	1648.62	54.57	
97	100.0	4238.98	95.84	
96	99.4	4231.21	42.00	
95	90.0	2414.29	60.26	
94	100.0	4732.24	78.66	
..	...	...	...	
101	100.0	3125.73	62.94	
100	82.3	230.04	22.83	
99	100.0	4125.24	60.90	
9	99.3	2856.43	44.76	
0	100.0	731.88	99.78	

	Launch Vehicle
98	Falcon Heavy
97	Falcon Heavy
96	Ariane 6
95	Falcon Heavy
94	Falcon Heavy
..	...
101	Falcon Heavy
100	Falcon Heavy
99	Starship
9	Starship

```
0              SLS

[500 rows x 15 columns]
```

In [115…
```
print("\nOrdenar por fecha de lanzamiento.")
df_ordenado_fecha = df.sort_values(by="Launch Date")
df_ordenado_fecha
```

```
Ordenar por fecha de lanzamiento.
```

Out[115]:

	Mission ID	Mission Name	Launch Date	Target Type	Target Name	Mission Type	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	S
0	MSN-0001	Mission-1	2025-01-01	Star	Titan	Colonization	7.05	5.2	526.68	
1	MSN-0002	Mission-2	2025-01-08	Exoplanet	Betelgeuse	Colonization	41.76	23.0	234.08	
2	MSN-0003	Mission-3	2025-01-15	Asteroid	Mars	Exploration	49.22	28.8	218.68	
3	MSN-0004	Mission-4	2025-01-22	Exoplanet	Titan	Colonization	26.33	17.8	232.89	
4	MSN-0005	Mission-5	2025-01-29	Exoplanet	Proxima b	Mining	8.67	9.2	72.14	
...	...	...	...	...	...	...	...	...	...	
495	MSN-0496	Mission-496	2034-06-28	Planet	Betelgeuse	Colonization	48.26	25.3	274.82	
496	MSN-0497	Mission-497	2034-07-05	Asteroid	Betelgeuse	Exploration	0.35	4.1	379.71	
497	MSN-0498	Mission-498	2034-07-12	Planet	Ceres	Exploration	47.60	26.6	296.45	
498	MSN-0499	Mission-499	2034-07-19	Planet	Betelgeuse	Research	31.99	18.0	457.38	
499	MSN-0500	Mission-500	2034-07-26	Planet	Io	Exploration	43.41	23.5	449.40	

500 rows × 15 columns

Agregaciones estadisticas.

- Calculamos estadísticas y realizamos agregaciones para obtener insights.

In [127…
```
print("\nContar misiones por destino")
misiones_por_destino = df["Mission Type"].value_counts()
print("Misiones por destino:")
print(misiones_por_destino)
```

```
Contar misiones por destino
Misiones por destino:
Mission Type
Research        132
Exploration     127
Colonization    125
Mining          116
Name: count, dtype: int64
```

In [ ]:
```python
print('\nCalcular la duración promedio de las misiones (Años luz)')
if "Distance from Earth (light-years)" in df.columns:
    duracion_promedio = df["Distance from Earth (light-years)"].mean()
    print("Duración promedio de las misiones:", duracion_promedio)
```

```
Calcular la duración promedio de las misiones (si existe una columna de duración
Duración promedio de las misiones: 25.48306
```

In [126…
```python
print("\nAgrupar por agencia espacial y contar misiones")
misiones_por_agencia = df.groupby("Mission Type")["Mission Name"].count()
print("Misiones por agencia:")
print(misiones_por_agencia)
```

```
Agrupar por agencia espacial y contar misiones
Misiones por agencia:
Mission Type
Colonization    125
Exploration     127
Mining          116
Research        132
Name: Mission Name, dtype: int64
```

Separacion de columnas por Numericas y Categoricas.

- Pandas nos permite filtrar columnas por tipo de datos usando select_dtypes.

In [133…
```python
# Seleccionar columnas numéricas
df_numericas = df.select_dtypes(include=['int64', 'float64'])
df_numericas
```

Out[133]:

	Distance from Earth (light-years)	Mission Duration (years)	Mission Cost (billion USD)	Scientific Yield (points)	Crew Size	Mission Success (%)	Fuel Consumption (tons)	Payload Weight (tons)
0	7.05	5.2	526.68	64.3	21	100.0	731.88	99.78
1	41.76	23.0	234.08	84.4	72	89.6	4197.41	45.72
2	49.22	28.8	218.68	98.6	16	98.6	4908.00	36.12
3	26.33	17.8	232.89	36.0	59	90.0	2569.05	40.67
4	8.67	9.2	72.14	96.5	31	73.2	892.76	12.40
...	...	...	...	...	...	...	...	...
495	48.26	25.3	274.82	91.2	64	96.2	4837.16	44.97
496	0.35	4.1	379.71	82.6	61	100.0	62.59	67.88
497	47.60	26.6	296.45	98.6	29	100.0	4794.01	51.38
498	31.99	18.0	457.38	77.9	39	100.0	3102.16	86.28
499	43.41	23.5	449.40	45.4	88	100.0	4302.93	86.74

500 rows × 8 columns

In [134…

```
# Seleccionar columnas categóricas (objetos y fechas)
df_categoricas = df.select_dtypes(include=['object'])
df_categoricas
```

Out[134]:

	Mission ID	Mission Name	Target Type	Target Name	Mission Type	Launch Vehicle
0	MSN-0001	Mission-1	Star	Titan	Colonization	SLS
1	MSN-0002	Mission-2	Exoplanet	Betelgeuse	Colonization	Starship
2	MSN-0003	Mission-3	Asteroid	Mars	Exploration	Starship
3	MSN-0004	Mission-4	Exoplanet	Titan	Colonization	Starship
4	MSN-0005	Mission-5	Exoplanet	Proxima b	Mining	Starship
...	...	...	...	...	...	...
495	MSN-0496	Mission-496	Planet	Betelgeuse	Colonization	Ariane 6
496	MSN-0497	Mission-497	Asteroid	Betelgeuse	Exploration	SLS
497	MSN-0498	Mission-498	Planet	Ceres	Exploration	Falcon Heavy
498	MSN-0499	Mission-499	Planet	Betelgeuse	Research	SLS
499	MSN-0500	Mission-500	Planet	Io	Exploration	Falcon Heavy

500 rows × 6 columns

Manejo de datos en diversos formatos.

Archivos CSV (Comma-Separated Values)

- El formato csv es uno de los más comunes para almacenar y compartir datos.
- Para leer un archivo CSV con Pandas usamos pd.read_csv()

Algunos parametros utiles en read_csv()

In [139…
```
#import pandas as pd

# Leer un archivo CSV
#df_csv = pd.read_csv("space_missions.csv")


'''
df_csv = pd.read_csv("space_missions.csv",
                     sep=",",      # Separador de columnas (por defecto es ",")
                     encoding="utf-8",  # Codificación del archivo
                     skiprows=1,   # Omitir la primera fila (si es necesario)
                     na_values=["N/A", "NA", "None"])  # Tratar ciertos valores com
'''
```

Out[139]:
```
'\ndf_csv = pd.read_csv("space_missions.csv", \n                    sep=",",
# Separador de columnas (por defecto es ",")\n                    encoding="utf-
8",  # Codificación del archivo\n                       skiprows=1,   # Omitir la pr
imera fila (si es necesario)\n                    na_values=["N/A", "NA", "Non
e"])  # Tratar ciertos valores como nulos\n'
```

Vamos a instalar librerías necesarias para hacer la conexión a MySQL, para poder hacer un EDA la Base de Datos.

- pymysql Permite la conexión con MySQL desde Python.
- SQLAlchemy Proporciona una interfaz para interactuar con base de datos SQL desde pandas

In [145…
```
%pip install pymysql sqlalchemy pandas
```

```
Collecting pymysql
  Downloading PyMySQL-1.1.1-py3-none-any.whl.metadata (4.4 kB)
Collecting sqlalchemy
  Downloading SQLAlchemy-2.0.38-cp311-cp311-win_amd64.whl.metadata (9.9 kB)
Requirement already satisfied: pandas in c:\python\python311\lib\site-packages (2.
2.1)
Collecting greenlet!=0.4.17 (from sqlalchemy)
  Downloading greenlet-3.1.1-cp311-cp311-win_amd64.whl.metadata (3.9 kB)
Collecting typing-extensions>=4.6.0 (from sqlalchemy)
  Downloading typing_extensions-4.12.2-py3-none-any.whl.metadata (3.0 kB)
Requirement already satisfied: numpy<2,>=1.23.2 in c:\python\python311\lib\site-pa
ckages (from pandas) (1.26.3)
Requirement already satisfied: python-dateutil>=2.8.2 in c:\users\lalo\appdata\roa
ming\python\python311\site-packages (from pandas) (2.8.2)
Requirement already satisfied: pytz>=2020.1 in c:\python\python311\lib\site-packag
es (from pandas) (2024.1)
Requirement already satisfied: tzdata>=2022.7 in c:\python\python311\lib\site-pack
ages (from pandas) (2024.1)
Requirement already satisfied: six>=1.5 in c:\users\lalo\appdata\roaming\python\py
thon311\site-packages (from python-dateutil>=2.8.2->pandas) (1.16.0)
Downloading PyMySQL-1.1.1-py3-none-any.whl (44 kB)
   ---------------------------------------- 45.0/45.0 kB 739.0 kB/s eta 0:00:00
Downloading SQLAlchemy-2.0.38-cp311-cp311-win_amd64.whl (2.1 MB)
   ---------------------------------------- 2.1/2.1 MB 6.1 MB/s eta 0:00:00
Downloading greenlet-3.1.1-cp311-cp311-win_amd64.whl (298 kB)
   ---------------------------------------- 298.9/298.9 kB 6.3 MB/s eta 0:00:00
Downloading typing_extensions-4.12.2-py3-none-any.whl (37 kB)
Installing collected packages: typing-extensions, pymysql, greenlet, sqlalchemy
  Attempting uninstall: typing-extensions
    Found existing installation: typing_extensions 4.5.0
    Uninstalling typing_extensions-4.5.0:
      Successfully uninstalled typing_extensions-4.5.0
Successfully installed greenlet-3.1.1 pymysql-1.1.1 sqlalchemy-2.0.38 typing-exten
sions-4.12.2
Note: you may need to restart the kernel to use updated packages.
ERROR: pip's dependency resolver does not currently take into account all the pack
ages that are installed. This behaviour is the source of the following dependency
conflicts.
tensorflow-intel 2.15.0 requires keras<2.16,>=2.15.0, but you have keras 3.0.4 whi
ch is incompatible.

[notice] A new release of pip is available: 24.0 -> 25.0.1
[notice] To update, run: python.exe -m pip install --upgrade pip
```

Conectar Pandas con MySQL

- Para conectar Pandas con una base de dato MySQL, necesitamos los datos de la conexión.

In [ ]:

```python
import pandas as pd
from sqlalchemy import create_engine

# Datos de conexión
usuario = ""       # Tu usuario de MySQL
password = ""  # Tu contraseña de MySQL
host = "localhost"     # Dirección del servidor (si está en la nube, usa la IP o UR
puerto = "3306"        # Puerto por defecto de MySQL
base_de_datos = "agendacontactos"  # Nombre de tu base de datos

# Crear la conexión con SQLAlchemy
engine = create_engine(f"mysql+pymysql://{usuario}:{password}@{host}:{puerto}/{base

# Verificar conexión
```

```
try:
    with engine.connect() as connection:
        print(" Conexión exitosa a MySQL")
except Exception as e:
    print(f" Error al conectar: {e}")
```

✅ Conexión exitosa a MySQL

Leer datos desde MySQL

- Si ya tenemos una tabla en la base de datos, podemos leerla con Pandas usando pd.read_sql()

In [147…

```
# Leer la tabla desde MySQL
df_sql = pd.read_sql("SELECT * FROM contacto", con=engine)

# Mostrar las primeras filas
print(df_sql.head())
```

```
   id     celular              email fecha_nacimiento      fecha_registro  \
0   1    65123863  karen@hotmail.com       1991-05-30 2024-03-04 12:04:11
1   2    78965422      msf@gmail.com       1968-01-19 2024-03-04 12:06:01
2   3     9632488      edi@gmail.com       1988-03-13 2024-03-04 12:07:16
3   4    97531896      pao@gmail.com       1998-07-22 2024-03-04 12:09:30
4   6  5151515151     lalo@gmail.com       1990-02-02 2024-03-04 12:45:22

       nombre
0  karen Aide
1       mario
2       edgar
3       paola
4        lalo
```

Guardar un DataFrame en MySQL

- Si queremos guardar un DataFrame en una tabla de MySQL usamos to_sql()

In [ ]:

```
df_sql.to_sql(name="pruebaPandas", con=engine, if_exists="replace", index=False)

print(" Datos guardados en la tabla 'pruebaPandas'")
```

✅ Datos guardados en la tabla 'pruebaPandas'

```
C:\Users\Lalo\AppData\Local\Temp\ipykernel_20152\970577762.py:1: UserWarning: The
provided table name 'pruebaPandas' is not found exactly as such in the database af
ter writing the table, possibly due to case sensitivity issues. Consider using low
er case table names.
  df_sql.to_sql(name="pruebaPandas", con=engine, if_exists="replace", index=False)
```

Verificamos que se guardo el data en la base de datos de MySQL.

In [152…

```
df_sql = pd.read_sql("SHOW TABLES", con=engine)
df_sql
```

Out[152]:

	Tables_in_agendacontactos
0	contacto
1	pruebapandas

Fusión y combinación de DataFrames

- Cuando trabajamos con datos, es común que la información este dividida en multiples fuentes.
- Pandas nos proporciona herramientas para fusionar, conectar y combinar DataFrames de manera eficiente.

Concatenación por filas (axis=0)

In [153…
```python
import pandas as pd

# Crear dos DataFrames de misiones espaciales
df1 = pd.DataFrame({
    "Mission_Name": ["Apollo 11", "Apollo 12"],
    "Agency": ["NASA", "NASA"],
    "Year": [1969, 1969]
})

df2 = pd.DataFrame({
    "Mission_Name": ["Voyager 1", "Voyager 2"],
    "Agency": ["NASA", "NASA"],
    "Year": [1977, 1977]
})

# Concatenar los DataFrames (apilando filas)
df_concat = pd.concat([df1, df2], ignore_index=True)
print(df_concat)
```

```
  Mission_Name Agency  Year
0    Apollo 11   NASA  1969
1    Apollo 12   NASA  1969
2    Voyager 1   NASA  1977
3    Voyager 2   NASA  1977
```

Concatenación por columnas (axis=0)

- Si tenemos DataFrames con el mismo número de filas, podemos unirlos por columnas.

In [154…
```python
df3 = pd.DataFrame({
    "Rocket_Type": ["Saturn V", "Saturn V", "Titan IIIE", "Titan IIIE"]
})

# Concatenar columnas
df_concat_col = pd.concat([df_concat, df3], axis=1)
print(df_concat_col)
```

```
  Mission_Name Agency  Year Rocket_Type
0    Apollo 11   NASA  1969    Saturn V
1    Apollo 12   NASA  1969    Saturn V
2    Voyager 1   NASA  1977  Titan IIIE
3    Voyager 2   NASA  1977  Titan IIIE
```

Fusión de DataFrames (pd.merge())

- LA función pd.merge() ns permite combinar DataFrames basándonos en una columna clave (similar a un JOIN)

In [155…
```python
df_misiones = pd.DataFrame({
    "Mission_ID": [1, 2, 3],
    "Mission_Name": ["Apollo 11", "Voyager 1", "Curiosity"],
    "Agency": ["NASA", "NASA", "NASA"]
})
```

```
df_costos = pd.DataFrame({
    "Mission_ID": [1, 2, 3],
    "Cost_Million": [355, 865, 2500]
})

# Fusionar usando la columna "Mission_ID" como clave
df_merge = pd.merge(df_misiones, df_costos, on="Mission_ID")
print(df_merge)
```

```
   Mission_ID Mission_Name Agency  Cost_Million
0           1    Apollo 11   NASA           355
1           2    Voyager 1   NASA           865
2           3    Curiosity   NASA          2500
```

Unión de DataFrames con (df.join())

- El método df.join() es útil para combinar DataFrames basándose en el índice.

In [156…

```
df_info = pd.DataFrame({
    "Mission_Name": ["Apollo 11", "Voyager 1", "Curiosity"],
    "Launch_Year": [1969, 1977, 2011]
}).set_index("Mission_Name")

df_agencias = pd.DataFrame({
    "Mission_Name": ["Apollo 11", "Voyager 1", "Curiosity"],
    "Agency": ["NASA", "NASA", "NASA"]
}).set_index("Mission_Name")

# Unir por índice
df_join = df_info.join(df_agencias)
print(df_join)
```

```
             Launch_Year Agency
Mission_Name
Apollo 11           1969   NASA
Voyager 1           1977   NASA
Curiosity           2011   NASA
```

Tipos de funciones en merge()

- Dependiendo de cómo queramos combinar los datos, usamos diferentes métodos.

1. Inner Join (how="inner") Solo mantiene los valores que existen en ambas tablas.
2. Left Join (how="left") Mantiene todos los valores de la izquierda y completa con NaN los faltantes.
3. Right Join (how="right") Mantiene todos los valores de la derecha.
4. Full Outer Join (how="outer") Mantiene todos los valores de ambas tablas y completa con NaN los faltantes.

Integración con otras Librerías en Pandas

Integración con NumPy:

- Pandas esta construido sobre NumPy, lo que permite usar funciones y operaciones de arrays.

In [1]:

```
import pandas as pd
import numpy as np
```

```
# Crear DataFrame
df = pd.DataFrame({
    "A": [1, 2, 3],
    "B": [4, 5, 6]
})

# Convertir a array NumPy
array = df.to_numpy()
print(array)
```

```
[[1 4]
 [2 5]
 [3 6]]
```

Integración con Matplotlib y Seaborn:

- Pandas facilita la integración de datos mediante Matplotlib y Seaborn.

In [2]:
```
import matplotlib.pyplot as plt

# Crear gráfico de línea
df.plot(x="A", y="B", kind="line")
plt.show()
```

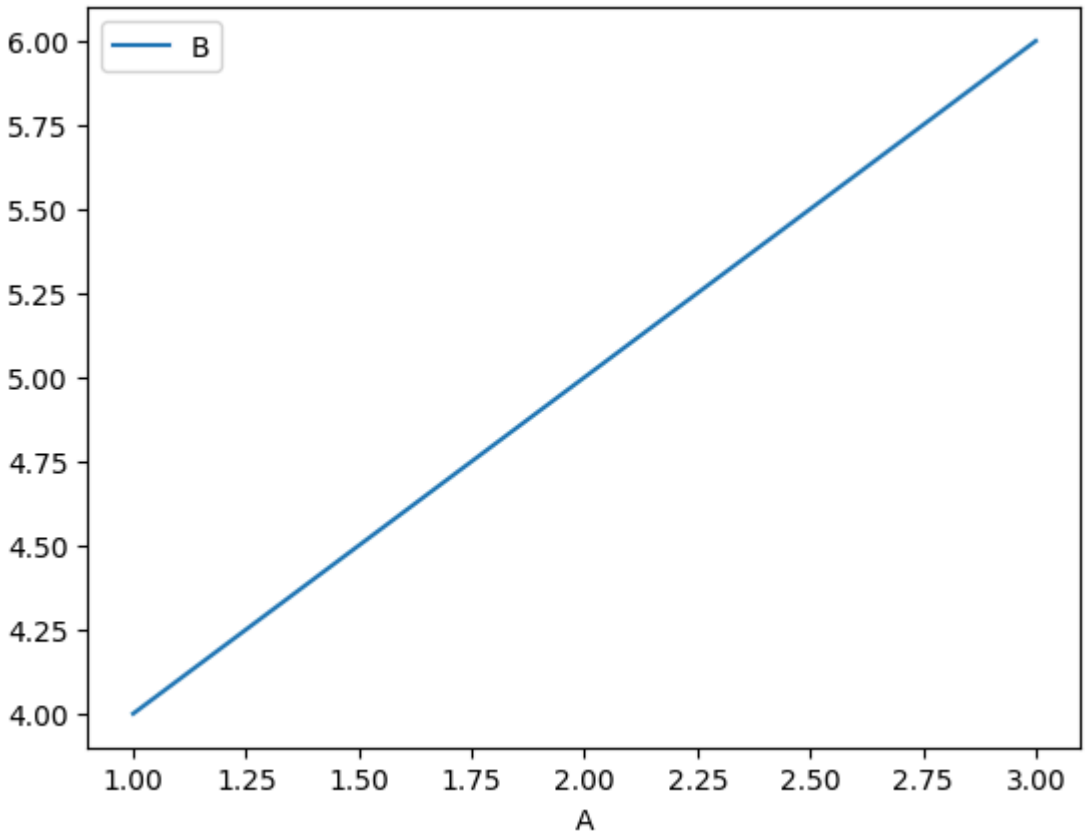

In [3]:
```
import seaborn as sns

# Crear gráfico de dispersión
sns.scatterplot(data=df, x="A", y="B")
plt.show()
```

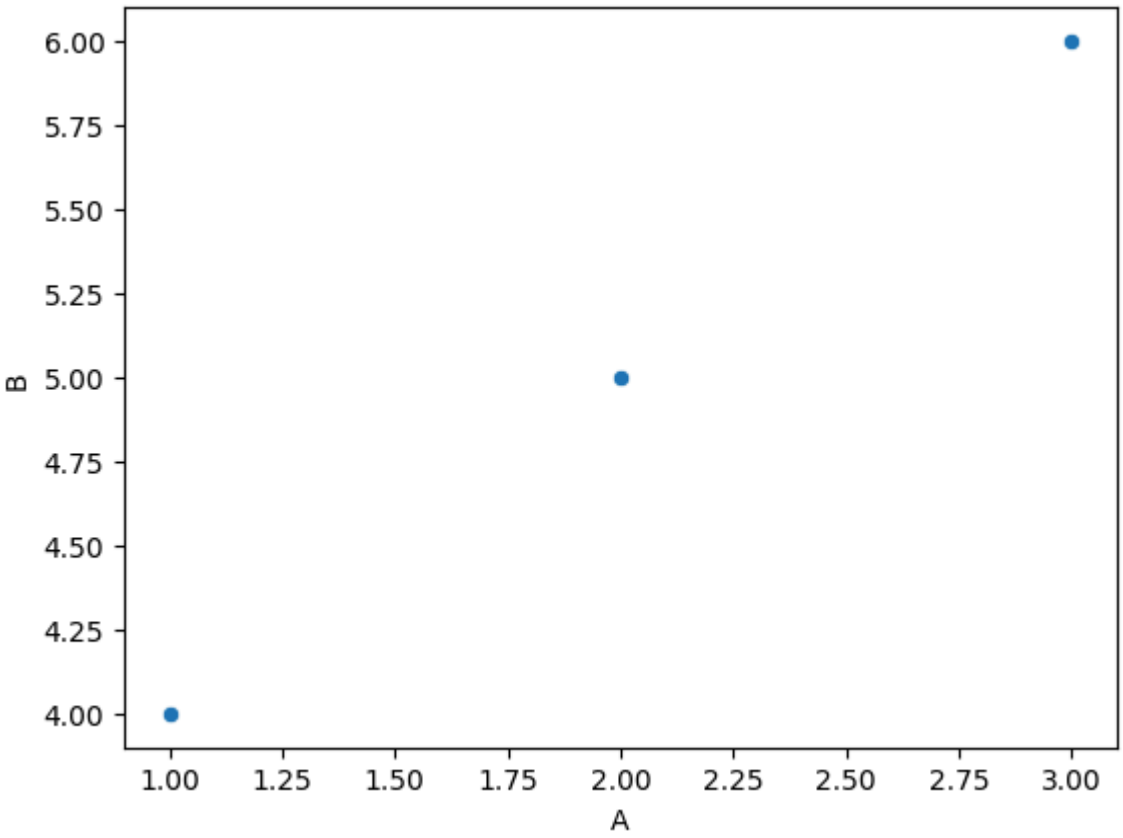

Integración con SciPy:

- Permite aplicar funciones estadísticas avanzadas a DataFrames.

In [ ]:
```
from scipy import stats

# Calcular la media y la mediana
media = df["B"].mean()
mediana = df["B"].median()
moda = stats.mode(df["B"])

print(f"Media: {media}, Mediana: {mediana}, Moda: {moda.mode[0]}")
```

Integración con Scikit-learn:

- Permite aplicar algoritmos de aprendizaje para entrenar modelos.

In [5]:
```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
df_scaled = pd.DataFrame(scaler.fit_transform(df), columns=df.columns)

print(df_scaled.head())
```

```
          A         B
0 -1.224745 -1.224745
1  0.000000  0.000000
2  1.224745  1.224745
```

Integración con SQL

- Pandas permite leer y escribir datos en bases de datos SQL con SQLALchemy

In [ ]:
```python
from sqlalchemy import create_engine

# Crear conexión
engine = create_engine("mysql+pymysql://usuario:contraseña@localhost/basedatos")

# Leer datos de una tabla
df_sql = pd.read_sql("SELECT * FROM misiones_espaciales", con=engine)

# Insertar DataFrame en MySQL
df_sql.to_sql("misiones_nuevas", con=engine, if_exists="replace", index=False)
```

Por: Eduardo Soto.

Ing de Software UACM